





# POLYNOMIALE REGRESSION

# DAS PROBLEM

- Daten beschreiben die nicht lineare Zusammenhänge haben
- Ähnlich zu Thema letzter Sitzung



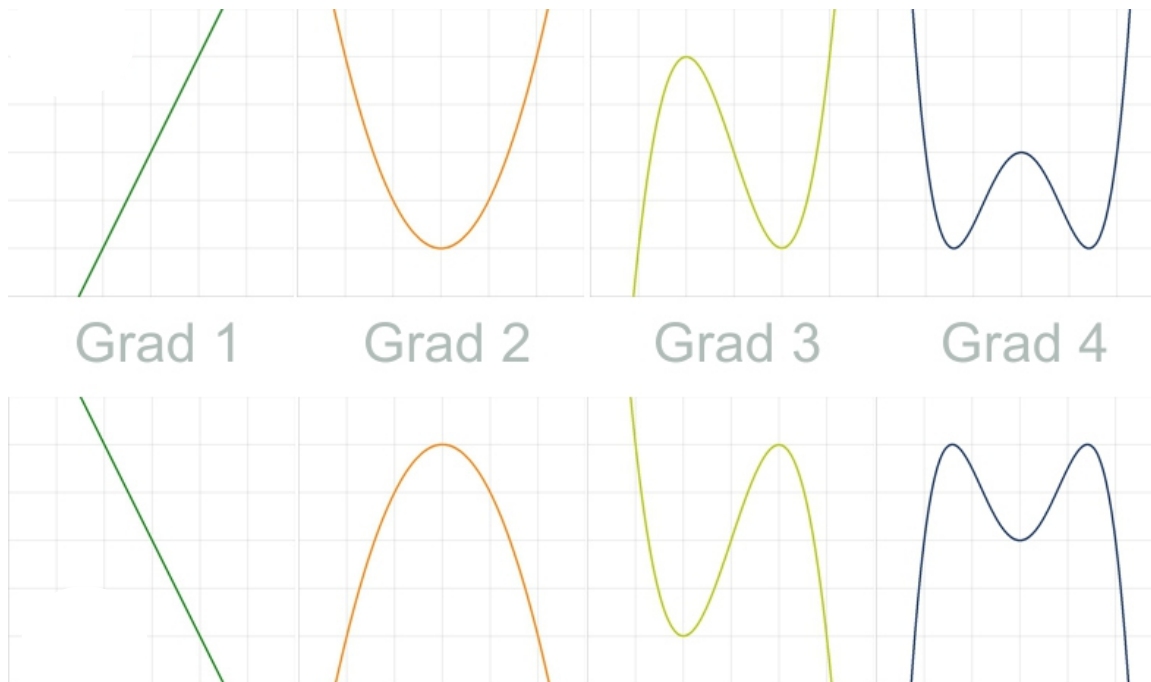




DIE LÖSUNG

WAS SIND POLYNOME?

$$\hat{y} = a + b_1x + b_2x^2 + b_3x^3 + \dots + b_nx^n$$



# VERSCHIEDENE ARTEN VON POLYNOMEN

Problem – welcher Grad soll die  
Funktion haben?

# PRINZIP

- Annahme von Polynome 2. Ordnung

$$\hat{y} = a + b_1 \cdot x + b_2 \cdot x^2.$$

- Summe der quadrierten Abweichungen minimieren

$$\sum_{i=1}^n [y_i - (a + b_1 \cdot x_i + b_2 \cdot x_i^2)]^2$$

Nach Bortz

# PRINZIP

$$\begin{aligned}\sum_i y_i &= an & +b_1 \sum_i x_i + b_2 \sum_i x_i^2, \\ \sum_i x_i \cdot y_i &= a \sum_i x_i & +b_1 \sum_i x_i^2 + b_2 \sum_i x_i^3, \\ \sum_i x_i^2 \cdot y_i &= a \sum_i x_i^2 & +b_1 \sum_i x_i^3 + b_2 \sum_i x_i^4.\end{aligned}$$

Lineares Gleichungssystem

Verweis auf Substitutionsverfahren  
Oder Gauß

Nach Bortz



# PRINZIP

Objekt-Nr.	$x$	$y$	$x \cdot y$	$x^2$	$x^3$	$x^4$	$x^2 \cdot y$
1	1,1	1,3	1,43	1,21	1,33	1,46	1,57
2	1,3	3,7	4,81	1,69	2,20	2,86	6,25
3	1,5	4,4	6,60	2,25	3,38	5,06	9,90
4	2,2	5,4	11,88	4,84	10,65	23,43	26,14
5	2,5	5,8	14,50	6,25	15,63	39,06	36,25
6	3,3	5,5	18,15	10,89	35,94	118,59	59,90
7	3,4	5,2	17,68	11,56	39,30	133,63	60,11
8	3,7	2,9	10,73	13,69	50,65	187,42	39,70
9	3,8	3,7	14,06	14,44	54,87	208,51	53,43
10	4,1	2,0	8,20	16,81	68,92	282,58	33,62
Summen:	26,9	39,9	108,04	83,63	282,87	1002,60	326,87

Nach Bortz

# PRINZIP


$$\begin{aligned}\sum_i y_i &= a n + b_1 \sum_i x_i + b_2 \sum_i x_i^2, \\ \sum_i x_i \cdot y_i &= a \sum_i x_i + b_1 \sum_i x_i^2 + b_2 \sum_i x_i^3, \\ \sum_i x_i^2 \cdot y_i &= a \sum_i x_i^2 + b_1 \sum_i x_i^3 + b_2 \sum_i x_i^4.\end{aligned}$$

$x$	$y$	$x \cdot y$	$x^2$	$x^3$	$x^4$	$x^2 \cdot y$
26,9	39,9	108,04	83,63	282,87	1002,60	326,87

$$\begin{aligned}39,9 &= 10 \cdot a + 26,9 \cdot b_1 + 83,63 \cdot b_2, \\ 108,04 &= 26,9 \cdot a + 83,63 \cdot b_1 + 282,87 \cdot b_2, \\ 326,87 &= 83,63 \cdot a + 282,87 \cdot b_1 + 1002,60 \cdot b_2.\end{aligned}$$

Nach Bortz

# PRINZIP



<https://www.arndt-bruenner.de/mathe/scripts/gleichungssysteme.htm>

# PRINZIP

$$\hat{y} = a + b_1x + b_2x^2 + b_3x^3$$

$$\hat{y} = a + b_1x_1 + b_2x_2 + b_3x_3$$

$$x_1 = x, x_2 = x^2, x_3 = x^3$$

# UMSETZUNG

- `import numpy as np`
- `import pandas as pd`
- `import matplotlib.pyplot as plt`

# UMSETZUNG I - NUMPY

```
import numpy as np
import statsmodels.formula.api as smf
```

#Input as array with 1 dimension

```
#data
x = np.array([0.0, 1.0, 2.0, 3.0, 4.0, 5.0])
y = np.array([0.0, 0.8, 0.9, 0.1, -0.8, -1.0])
```

Polyfit  
Returns Polynomial coefficients, highest power first.

```
#grad der Funktion
degree = 3
```

```
#für die Summary benötigt
df = pd.DataFrame(columns=['y', 'x'])
df['x'] = x
df['y'] = y
```

```
weights = np.polyfit(x, y, degree)
```

```
model = np.poly1d(weights)
results = smf.ols(formula='y ~ model(x)', data=df).fit()
```

# UMSETZUNG NUMPY II

```
#Results
print(results.summary())

#Visualisierung
plt.scatter(x, y, color = 'blue')

xModel = np.linspace(min(x), max(x))
yModel = np.polyval(weights, xModel)

plt.plot(xModel, yModel)

plt.title('Polynomial Regression')
plt.xlabel('X')
plt.ylabel('Y')

plt.show()
```

# UMSETZUNG II - SKLEARN

```
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
import statsmodels.api as sm

#input als 2-d array

#data
x = np.array([0.0, 1.0, 2.0, 3.0, 4.0, 5.0])
y = np.array([0.0, 0.8, 0.9, 0.1, -0.8, -1.0])
x = x.reshape(-1,1)

poly = PolynomialFeatures(degree = 3)
X_poly = poly.fit_transform(x)

X_vals = np.linspace(min(x), max(x))
lin2 = LinearRegression()
lin2.fit(X_poly, y)
X_vals_poly = poly.transform(X_vals)
y_vals = lin2.predict(X_vals_poly)
```



# UMSETZUNG II – SKLEARN II

```
#results  
model = sm.OLS(y, X_poly).fit()  
print(model.summary())
```

```
#Visualisierung  
plt.scatter(x, y)  
plt.plot(X_vals, y_vals)  
plt.xlabel("X")  
plt.ylabel("Y")  
plt.show()
```



# ZUSAMMENFASSUNG UMSETZUNG

	Numpy	SKlearn
Input	Ein-dimensionales Array	Zwei-dimensionales Array
Summary	Über smf import statsmodels.formula.api as smf Braucht deswegen df	Über sm import statsmodels.api as sm
Prinzip	Berechnung der weights Dann Training des Models	Umwandlung in Lineare Regression – dann Training dieser
Predictions für einen Wert von 4.5	pred = 4.5 np.polyval(weights, pred)	pred = np.array(4.5) pred = pred.reshape(-1, 1) lin2.predict(poly.fit_transform(p red))

```
df1 =  
pd.read_csv(r"https://raw.githubusercontent.com/ck282/statistico812/main/salaries  
.txt", sep="\t")
```


# FRAGE NACH DEGREE

- Jackson: Grad größer als 3 oder 4 selten
- Gefahr Overfitting



```
plt.plot(degrees, rsquared)
```

```
[<matplotlib.lines.Line2D at 0x25282735c90>]
```



```
degrees = [1,2,3,5,9,14]
```

```
rsquared = []
```

```
for d in degrees:
```


```
    model = np.poly1d(np.polyfit(x, y, d))
```

```
    rsquare = smf.ols(formula='y ~ model(x)', data=df).fit().rsquared
```

```
    rsquared.append(rsquare)
```

```
plt.plot(degrees, rmse)
```

```
[<matplotlib.lines.Line2D at 0x25281f1df60>]
```



```
from statsmodels.tools.eval_measures import rmse
```

```
degrees = [1,2,3,5,9,14]
```

```
rmse = []
```

```
for d in degrees:
```

```
    weights = np.polyfit(x, y, d)
```

```
    ypred = np.polyval(weights, x)
```

```
    c_rmse = rmse(y, ypred)
```

```
    rmse.append(c_rmse)
```

# HAUSAUFGABE

- Aufgabe 1: <https://raw.githubusercontent.com/ck282/statistic0812/main/salaries.txt>
- A) Plote die Daten mit einer polynomialen Regression mit einem Grad von 3. Benutze dabei entweder numpy oder sklearn.
- B) Was ist die Funktionsgleichung?
- C) Treffe eine Vorhersage für einen x-Wert von 6.5
- D) Wähle eine bereits behandelte Modellierung aus und vergleiche, ob diese besser oder schlechter auf die Daten passt.

Aufgabe 2: <https://raw.githubusercontent.com/ck282/statistic0812/main/values.txt>

- Lade die Daten ein und finde heraus welcher Grad/Degree für die Daten am besten geeignet ist, begründe deine Antwort.

# QUELLEN

- Bortz, Jürgen. *Statistik: Für Human- und Sozialwissenschaftler (Springer Lehrbuch)*. 6., Vollst. überarb. u. aktualisierte, Springer, 2022.
- Jackson, Dr. S. *Chapter 7 Polynomial Regression | Machine Learning*. 6. April 2022, [bookdown.org/ssjackson300/Machine-Learning-Lecture-Notes/polynomial-regression.html](https://bookdown.org/ssjackson300/Machine-Learning-Lecture-Notes/polynomial-regression.html).
- Loong, Joshua. „Fitting Polynomial Regressions in Python“. *Joshua Loong*, 3. Oktober 2018, [joshualoong.com/2018/10/03/Fitting-Polynomial-Regressions-in-Python](https://joshualoong.com/2018/10/03/Fitting-Polynomial-Regressions-in-Python).
- *Polynomial Regression - which python package to use?* <https://zerowithdot.com/polynomial-regression-in-python/>
- *Python Machine Learning Polynomial Regression*. [www.w3schools.com/python/python\\_ml\\_polynomial\\_regression.asp](https://www.w3schools.com/python/python_ml_polynomial_regression.asp).
- *Vorlesung Intelligente Datenanalyse*. [fuzzy.cs.ovgu.de/studium/ida](https://fuzzy.cs.ovgu.de/studium/ida).